Pontificia Universidad Católica de Chile
Instituto de Ingeniería Matemática y Computacional
Álgebra Lineal Avanzada y Modelamiento - IMT2230

Proyecto 1: LSA con SVD

Profesor: Felipe Urrutia
Ayudante: Luis Castillo

Objetivo

En este proyecto aplicaran la descomposicion en valores singulares a una coleccion de textos para descubrir estructura latente en los datos. La meta es usar herramientas de algebra lineal para representar documentos y terminos en dimension reducida, interpretar los resultados y discutir sus limites.

Indicaciones Generales

- **Grupos:** El proyecto se realiza en grupos de **2 o 3 estudiantes**.
- **Corpus:** Cada grupo debe elegir un corpus propio. Los datos deben ser publicos y reproducibles.
- **Codigo:** El codigo debe quedar en un repositorio publico de GitHub. El repositorio debe incluir instrucciones de ejecucion, enlace o instrucciones para descargar los datos, y los archivos necesarios para reproducir figuras y resultados.
- **Informe:** Se debe entregar un informe final en formato `.pdf`. El informe debe ser breve, claro y bien estructurado. Puede escribirse en Overleaf o en otra herramienta, pero el resultado final debe ser un PDF.
- **Fechas:** La publicacion del proyecto corresponde a la semana 8 del curso. La entrega corresponde a la semana 11 del curso. Revisen el calendario oficial del curso para confirmar la fecha exacta.

Herramientas Esperadas

Python debiera ser el lenguaje principal del proyecto. Una combinacion razonable de librerias es:

- `numpy` para algebra lineal y manejo de arreglos;
- `pandas` para tablas y organizacion de datos;
- `matplotlib` o `seaborn` para visualizaciones;
- `scikit-learn` para construir matrices documento-palabra o termino-documento con TF-IDF;
- `scipy` si necesitan trabajar con matrices dispersas;

- `nltk` o `spaCy` para tareas basicas de procesamiento de texto.

Pueden trabajar en Google Colab o en un notebook de Jupyter local. Lo importante es que el codigo sea facil de ejecutar y reproducir.

Uso de herramientas de IA

Pueden usar herramientas como GitHub Copilot, Codex, ChatGPT u otras similares para apoyar el desarrollo. Su uso es permitido, pero ustedes siguen siendo responsables del contenido entregado. Deben entender el codigo que usan, revisar y corregir errores, verificar los resultados y escribir un informe que refleje comprension real del analisis matematico.

Descripcion del proyecto

El objetivo de este proyecto es realizar un analisis semantico latente, o LSA por su nombre en ingles *Latent Semantic Analysis*, usando SVD.

La idea central es construir una matriz que represente una coleccion de documentos, aplicar SVD, conservar algunas componentes principales e interpretar la representacion reducida como una aproximacion de la estructura semantica del corpus.

P 1 (Eleccion y descripcion del corpus)**.** Elijan un corpus con al menos 50 documentos. Cada documento debe tener una cantidad razonable de texto y la fuente debe ser abierta.

Describan la fuente de los datos, indiquen cuantos documentos usaran y expliquen por que el corpus es interesante. Incluyan una tabla o resumen con el numero de documentos y la fuente.

Algunos ejemplos posibles son abstracts de articulos cientificos, noticias, discursos politicos, letras de canciones, reviews de productos u otro corpus publico que el grupo considere apropiado. Pueden buscar datos en Kaggle, Hugging Face Datasets u otras fuentes abiertas.

P 2 (Hipotesis inicial)**.** Antes de realizar el analisis, propongan una hipotesis sobre la estructura del corpus.

Por ejemplo, pueden anticipar temas posibles, grupos de documentos, palabras importantes o separaciones esperadas entre categorias. La salida esperada es un parrafo corto con una hipotesis inicial concreta.

P 3 (Preprocesamiento del texto)**.** Limpien el texto para construir un vocabulario util.

Como minimo, expliquen que decisiones tomaron sobre tokenizacion, normalizacion, eliminacion de stopwords y eliminacion de terminos poco informativos. Se recomienda usar TF-IDF en lugar de conteos crudos. Tambien pueden incluir lematizacion y n-gramas si esto ayuda al corpus elegido.

Reporten el tamano del vocabulario final y expliquen brevemente por que el preprocesamiento elegido es razonable.

P 4 (Construccion de la matriz textual)**.** Construyan la matriz que sera analizada con SVD.

Definan claramente si trabajaran con una matriz termino-documento o documento-palabra. En la clase usamos la convencion

$$A \in \mathbb{R}^{m \times n},$$

donde las filas representan terminos, las columnas representan documentos, m es el numero de terminos y n es el numero de documentos. Si usan `scikit-learn`, recuerden que sus vectorizadores suelen entregar una matriz con documentos en las filas y terminos en las columnas; pueden transponerla si quieren seguir la convencion del curso.

Reporten la dimension de la matriz y expliquen como fue construida. Si usan TF-IDF, definan brevemente que representa una entrada A_{ij}.

P 5 (Calculo de la SVD)**.** Calculen la descomposicion

$$A = U \Sigma V^T.$$

Expliquen que representan los valores singulares en este problema y que informacion entregan los vectores singulares izquierdos y derechos. Si A es una matriz termino-documento, las columnas de U describen direcciones principales en el espacio de terminos, mientras que las columnas de V describen direcciones principales en el espacio de documentos.

P 6 (Valores singulares y eleccion de dimension)**.** Analicen cuanto de la estructura del problema se concentra en pocas componentes.

Grafiquen los valores singulares, observen su decaimiento y elijan un valor razonable de k para una representacion reducida. Justifiquen brevemente la eleccion de k.

P 7 (Representacion de documentos y terminos en baja dimension)**.** Usen componentes de la SVD para construir representaciones reducidas.

Para visualizar en dos dimensiones, pueden elegir cualquier par de componentes. En particular, es natural comenzar con las dos primeras componentes, porque corresponden a los dos valores singulares mas grandes. Si siguen la convencion termino-documento de la clase y escriben

$$A_2 = U_2 \Sigma_2 V_2^T,$$

para las dos primeras componentes, entonces las coordenadas de los documentos estan dadas por

$$D_2 = \Sigma_2 V_2^T \in \mathbb{R}^{2 \times n},$$

y las coordenadas de los terminos estan dadas por

$$T_2 = U_2 \Sigma_2 \in \mathbb{R}^{m \times 2}.$$

Mas generalmente, si quieren visualizar las componentes a y b, usen las columnas correspondientes de U, las filas correspondientes de V^T y los valores singulares σ_a, σ_b.

Incluyan una visualizacion 2D de documentos y una visualizacion 2D de palabras o terminos relevantes, indicando que par de componentes usaron. Interpreten agrupamientos, separaciones o asociaciones observadas.

P 8 (Exploracion semantica)**.** Usen la representacion reducida para explorar relaciones en el corpus.

Incluyan 2 o 3 ejemplos concretos, como palabras cercanas, documentos cercanos, componentes con posible significado tematico o grupos de documentos que parezcan relacionados. Expliquen por que esos ejemplos son coherentes o sorprendentes.

P 9 (Discusion, limitaciones y conclusiones)**.** Comparen los resultados con la hipotesis inicial.

Indiquen si la hipotesis se cumple o no, expliquen resultados esperados e inesperados, y discutan limites del metodo y del corpus. Recuerden que LSA no reemplaza la lectura del corpus: sirve como herramienta exploratoria para descubrir patrones, formular hipotesis y construir visualizaciones de baja dimension.

Checklist minimo de entrega

La entrega debe incluir, al menos:

- corpus descrito y fuente citada;
- hipotesis inicial;
- matriz documento-palabra o termino-documento construida;
- SVD calculada;
- grafico de valores singulares;
- visualizacion 2D de documentos;
- visualizacion 2D de palabras o terminos;
- ejemplos de exploracion semantica;
- discusion final;
- codigo reproducible en GitHub.

Pauta general de evaluacion

- **Planteamiento del problema y del corpus (20 %):** corpus bien elegido, bien descrito y con una hipotesis inicial clara.

- **Construccion de la matriz y uso de SVD (25 %):** matriz bien definida, procedimiento correcto y uso adecuado de la descomposicion.
- **Analisis e interpretacion (30 %):** lectura correcta de valores singulares, visualizaciones utiles e interpretacion de resultados.
- **Claridad del informe (15 %):** redaccion clara, ordenada y precisa.
- **Reproducibilidad del codigo (10 %):** repositorio ordenado, ejecutable y suficiente para reproducir el trabajo.

Entrega ideal

Una entrega bien lograda deberia mostrar que el corpus esta bien explicado, que la fuente esta claramente indicada, que la hipotesis inicial se conecta con el analisis, que la matriz textual esta bien construida, que la SVD se usa correctamente y no solo como una caja negra, que las visualizaciones ayudan a entender el problema, que la discusion final compara resultados con la hipotesis inicial y que el repositorio permite repetir el analisis sin ambiguedad.