

# Proyecto 1: LSA con SVD

## P1. Elección y descripción del corpus.

Se utilizaron unos resúmenes de un videojuego de rol de acción (ARPG) llamado Genshin Impact. Este juego tiene una extensa historia, donde se consiguieron documentos realizados por la comunidad (Fuente: [https://genshin-impact.fandom.com/wiki/Inazuma/History#First\\_Era](https://genshin-impact.fandom.com/wiki/Inazuma/History#First_Era)) que relatan los eventos e historia del juego. El corpus cuenta con 50 documentos.

En este, se puede realizar SVD, lo que permite visualizar las relaciones que ocurren entre personajes, naciones y eventos dentro del mismo juego para así ver que tan relacionados están cada uno de estos elementos.

## P2. Hipótesis inicial.

Lo que inicialmente consideramos que puede pasar es que LSA podrá agrupar a los personajes más relevantes de cada nación (arcontes/dioses de la nación) con lugares importantes de sus respectivas naciones. Además, consideramos que los temas (o conceptos) como la guerra, el viajero y el orden celestial deben ser muy prevalentes en varias secciones, ya que estos son los puntos que normalmente relacionan naciones entre sí y son partes de la historia general.

### P3. Preprocesamiento del texto.

\*\*\*

|   | estadística                   | corpus_sin_limpieza | despues_preprocesamiento |
|---|-------------------------------|---------------------|--------------------------|
| 0 | numero_documentos             | 50                  | 50                       |
| 1 | numero_terminos               | 6181                | 3909                     |
| 2 | forma_X_documentos_x_terminos | 50 x 6181           | 50 x 3909                |
| 3 | forma_A_terminos_x_documentos | 6181 x 50           | 3909 x 50                |
| 4 | entradas_no_cero              | 19867               | 13581                    |
| 5 | densidad                      | 0.0643              | 0.0695                   |
| 6 | sparsity                      | 0.9357              | 0.9305                   |

\*\*\*

|   | estadística | corpus_sin_limpieza | despues_preprocesamiento |
|---|-------------|---------------------|--------------------------|
| 0 | min         | 192.00              | 90.00                    |
| 1 | mediana     | 645.00              | 328.00                   |
| 2 | media       | 816.14              | 420.98                   |
| 3 | max         | 2280.00             | 1214.00                  |

\*\*\*

|   | estadística | corpus_sin_limpieza | despues_preprocesamiento |
|---|-------------|---------------------|--------------------------|
| 0 | min         | 122.00              | 75.00                    |
| 1 | mediana     | 351.00              | 244.00                   |
| 2 | media       | 397.34              | 271.62                   |
| 3 | max         | 889.00              | 655.00                   |

\*\*\*

|   | estadística                   | antes      | despues    | cambio_% |
|---|-------------------------------|------------|------------|----------|
| 0 | numero_terminos               | 6181.0000  | 3909.0000  | -36.76   |
| 1 | entradas_no_cero              | 19867.0000 | 13581.0000 | -31.64   |
| 2 | densidad                      | 0.0643     | 0.0695     | 8.09     |
| 3 | sparsity                      | 0.9357     | 0.9305     | -0.56    |
| 4 | media_terminos_por_doc        | 816.1400   | 420.9800   | -48.42   |
| 5 | media_terminos_unicos_por_doc | 397.3400   | 271.6200   | -31.64   |

\*\*\*

|   | estadística                               | despues_preprocesamiento |
|---|-------------------------------------------|--------------------------|
| 0 | unigramas_vocabulario_final               | 2903                     |
| 1 | bigramas_vocabulario_final                | 1006                     |
| 2 | forma_X_final_tfidf_documentos_x_terminos | 50 x 3909                |
| 3 | forma_A_final_tfidf_terminos_x_documentos | 3909 x 50                |

Para construir un vocabulario útil y reducir el ruido en los datos (como conectivos), se aplicaron las siguientes medidas.

Primero, se ocupó la librería `spacy` para procesar el texto. Los tokens los redujimos a sus lemas, lo que permitió agrupar variaciones de una misma palabra a solo un concepto, mejorando así la precisión del SVD.


Después se hizo una lista de stopwords, el cual también se lematizo y se eliminaron todas las palabras con una longitud menor a 3 caracteres, ya que no aportan algún tipo de información vital.

Finalmente, se construyó la matriz utilizando TF-IDF y N-gramas. Se utilizó `n_gram_range=(1, 2)` combinaciones de palabras relevantes y se eliminan los términos que aparezcan en menos de 2 documentos (`min_df=2`) o que aparezcan en más del 80% del corpus (`max_df=0.8`).

Se hizo este preprocesamiento del texto para reducir el ruido de la matriz, pasando de 6181 términos en crudo a algo más reducido y concreto (3909 términos).

## P9. Discusión, limitaciones y conclusiones.

Las hipótesis están en su mayor parte correctas




Amarillos: Personajes o actores dentro del cataclismo (cataclismo es donde el abismo entra en el mundo de teyvat y ocurren los hechos). El gemelo del viajero fue la causa de este y el viajero actual aporta a acabar con el abismo actual que invade el mundo, además el viajero también es el protagonista, por ende, tiene sentido que sea lo más mencionado. También, los arcontes son los dioses de cada nación que también se encargan de mantener el abismo a raya dentro de sus naciones.

Morados: Entes del orden celestial o menciones del orden celestial (también aparecen en el cataclismo, ya que estos fueron los encargados de contener al abismo en los primeros momentos del cataclismo, pero son más relevantes en el balance del mundo), también dejó la luna como deidad, ya que las lunas esta fueron predecesoras al orden celestial actual, las cuales poseían la autoridad sobre el mundo.

Naranjos: Son los lugares relevantes del mundo del juego (ya sean naciones, otros mundos o el mismo teyvat el cual es el mundo donde transcurren los hechos).

Kaenria es la nación que en un experimento y soberbia humana terminan generando una puerta para que el abismo invada al mundo y corrompa partes del mundo, esta nación se verá castigada por los órdenes celestiales de la muerte (quitándoles la capacidad de morir y tener que vivir en una única conciencia y cuerpo) y la vida (a la gente que estuvo cerca de la brecha del abismo la convirtió en algo no humano, debido a que si no esas personas serian corrompidas por el abismo y serían una amenaza al resto de humanos), mientras que el orden del tiempo trato de mantener estables algunas naciones mientras la crisis ocurre.

Ahora viendo cercanía entre cosas




Morado: Nación del fuego (Natlan) y la guerra inspirada en pueblos precolombinos y africanos, se ven cosas como localidades (mare jivari, och kan, etc), también se ven objetos especiales que se utilizan para combatir el abismo (como, por ejemplo, el reino de la noche, una bendición de el orden celestial de la muerte, la llama sagrada como la conexión que tienen con el reino de la noche) también aparecen elementos por los que la nación es conocida (como Pyro que es el elemento de fuego y la presencia de dragones).

Rojo: Nacion de la naturaleza (Sumeru), donde los 2 personajes cercanos eran los dioses de esa tierra.

Morax: Dios de la nación de piedra y contratos, donde este no se ha visto muy envuelto en eventos de estas naciones en el contexto actual.

Naranja: Nación del viento y libertad, no esta muy cercana a estas naciones, más allá que algunos de sus personajes viajan seguido a natlan y es vecina de la nación de piedra.




Morado: Nación de la electricidad (Inazuma), es un archipiélago con muchas islas, donde las facciones principales aparecen cercanas unas de otras.

Verde: Actores del cataclismo y lo que ocurre dentro del mismo (el abismo entra a teyvat por culpa de los humanos de Khaenria, donde estos son castigados por el principio celestial de la muerte).

Rojo: Son las naciones más afectadas por la crisis del abismo (Inazuma no se vio tan afectada como Sumeru, ya que vio la muerte de sus 2 dioses a causa de la corrupción abismal). Natlan, estuvo en una guerra de más de 500 años con

monstruos que abrían brechas al abismo y destruían sus ciudades. También, Monstat vio una de sus deidades corrompida por el abismo, la cual termino atacando a su propia razón por lo mismo, además de tener residuos abismales en una gran zona de sus territorios, ya que esa nación fue protegida por el orden celestial del tiempo al ser la nación de la eternidad.



Morado: Personajes y lugares de Inazuma (nación del rayo y la eternidad), están los nombres de las islas del archipiélago y los dioses locales que pelearon con la diosa principal (y también aparece la hermana muerta de la diosa principal).

Verde: Las lunas eran parte del antiguo mundo (a su vez representadas por diosas antiguas) antes de ser usurpadas (la luna congelada es la que se quedó en el mundo luego que las otras 2 fueron destruidas por el usurpador).

Negro: Elementos de Natlan (nación del fuego y la guerra), la única excepción a esta regla es Montsadt, pero hay varios personajes que se relacionan entre estas 2 naciones (tienen doble nacionalidad o viajan seguido entre dichas naciones).

Se puede ver que los resultados obtenidos a través de los gráficos confirman en gran parte nuestra hipótesis inicial. Como se vio, el modelo fue capaz de separar los términos (generar clusters) según las naciones del juego. Se pudo ver que los personajes, lugares y elementos particulares aparecen relacionados directamente con sus respectivas naciones, también se pudo ver que los temas (o conceptos) como la guerra, el viajero y el orden celestial sí prevalecieron en las secciones.

Por otra parte, algunas limitantes que se pudieron ver es que aunque la gran mayoría de términos están relacionados exitosamente, este modelo no logra detectar qué relación tienen estos términos, por ejemplo, no logra saber que tipo de relación tienen los personajes o naciones (si es amistosa, conflictiva, entre otras), también el corpus elegido puede tener un sesgo, ya que al ser sacados de una wiki comunitaria, los documentos elegidos pueden tener una cierta preferencia a ciertos personajes o naciones indirectamente o directamente, dado que los autores pueden transmitir sus preferencias a través de estos documentos.

En conclusión, a pesar de unas limitantes, SVD logró ser muy eficaz relacionando cada término de los documentos sin tener un contexto previo, pudiendo ver relaciones interesantes y coherentes.

## Repositorio público de GitHub

<https://github.com/wbguc/Proyecto-Algebra/tree/main>